

Локально-аппроксимирующие модели для декодирования сигналов головного мозга

Маркин В. О

markin.vo@phystech.edu

Московский физико-технический институт

В работе рассматривается задача построения оптимального признакового описания в задаче декодирования сигналов. Рассматриваются электрические сигналы в коре головного мозга, записанные при помощи электрокортикографии (ECoG). Исходное признаковое пространство избыточно, модель прогнозирования оказывается неустойчивой. Для решения данной проблемы предлагается построить локальную модель аппроксимации сигнала. Это позволяет существенно снизить размерность признакового пространства и учесть пространственную структуру сигнала. В статье приведены результаты численных экспериментов на данных электрокортикограмм головного мозга обезьян. Проводится сравнение различных методов отбора признаков и гипотез порождения данных

Ключевые слова: *Локальные модели, отбор признаков, нейрокомпьютерный интерфейс*

Введение

Нейрокомпьютерный интерфейс (BCI) позволяет считывать сигналы нейронов головного мозга и декодировать их в команды исполняющей системы. Исследования в данной области позволяют восстанавливать дееспособность людей с нарушениями двигательных функций организма. Примером такой системы является система управления роботизированным протезом посредством мозговых импульсов.

Мозговая активность представляет собой совокупность электрических импульсов различной амплитуды и частоты, возникающих в коре головного мозга. Электроды, закрепленные в коре, позволяют считывать сигналы для их дальнейшего декодирования алгоритмами нейрокомпьютерного интерфейса.

Стандартные подходы к решению задачи состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала [1, 2]. Боль-

шинство методов в смежных работах исследуют частотные характеристики [3, 4, 5]. Наиболее распространёнными моделями являются алгоритмы PLS [6, 7, 4], PCA [8, 9]. В работе [10] используются алгоритмы, построенные на скрытых марковских моделях. В работах [5, 9] авторы рассматривают различные участки сигнала в виде слов. В работе [11] задача отбора признаков сводится к задаче квадратичного программирования (Quadratic Programming Feature Selection [12]). Также для решения задачи используются нейросетевые модели [13]. В этой работе для извлечения признаков используются сверточная нейронная сеть, а для предсказания - сеть LSTM.

В данной работе для учета пространственной структуры сигнала предлагается построить локальную модель аппроксимации сигнала, поступающего от электродов. Параметры полученной локальной модели используются в качестве нового признакового описания. Данный подход позволяет снизить размерность пространства признаков и повысить устойчивость модели. Для достижения лучшего качества предлагается использовать приемы, приведенные в работе [14]. В данной статье предлагается перед непосредственным предсказанием траектории движения кисти определить движется ли она в данный момент или нет. Предлагается предсказывать траекторию руки и ее скорость, так как скорость сильнее коррелирована с импульсами, чем координата.

В вычислительном эксперименте используются данные электрокортикограмм обезьян с сайта neurotycho.org.

Постановка задачи

Данные электрокортикограммы представляют собой зависимость $\mathbf{s}(t) \in \mathbb{R}^{N_{ch}}$ напряжения на каждом электроде от времени. N_{ch} – число каналов (электродов). Требуется предсказать координату кисти $\mathbf{y}(t) \in \mathbb{R}^3$. Сигнал $\mathbf{s}(t)$ посредством фильтрации и вейвлет-преобразования преобразуется в трехмерный тензор

$$\underline{\mathbf{D}} = \{\underline{\mathbf{X}}_m \in \mathbb{R}^{N_{ch} \times F \times T}, m \in \overline{1, M}\}$$

где M – число временных измерений, F – число частот, используемых в вейвлет-преобразовании, T – число временных точек в предыстории. Процедура построения \mathbf{D} проведена в описании эксперимента.

Регрессионную модель $\mathbf{y}_m = f(\mathbf{X}_m, \gamma)$, где γ – вектор параметров. Предлагается искать в классе суперпозиций двух моделей: $f = g \circ h$, где локально-аппроксимирующая модель $g : \mathbb{R}^{N_{ch}} \rightarrow \mathbb{R}^{N_f}$ строит признаковое описание сигнала в каждый момент времени (N_f – число признаков в полученном описании). Модель h по новым признакам прогнозирует ответ \mathbf{y}_m . В данной работе основное внимание уделяется выбору модели g , в качестве модели h используется метод частных наименьших квадратов (PLS).

$$\mathbf{s}(t) \in \mathbb{R}^{N_{ch}} \xrightarrow[\text{transform}]{\text{spectral}} \mathbf{X}_m \in \mathbb{R}^{N_{ch} \times T \times F} \xrightarrow[\text{model}]{\text{local}} \mathbf{\Theta}_m \in \mathbb{R}^{N_f \times T \times F} \xrightarrow{\text{PLS}} \mathbf{y}_m \in \mathbb{R}^3$$

Определение: Локальная модель временного ряда $\{s_m, m \in \overline{1, M}\}$ – параметрическое отображение

$$g : [s_{m-t}, \dots, s_m] \rightarrow [\hat{s}_{m-t}, \dots, \hat{s}_m], \forall m \in \overline{t, M}$$

где параметры этого отображения θ_m используются в качестве нового описания момента времени m .

В работе для построения признакового описания используется модель локальной аппроксимации $\hat{\mathbf{X}}_m = g(\mathbf{X}_m, \theta_m)$, где θ_m – вектор параметров модели, который используется как новое признаковое описание временного ряда $\theta_m \in \mathbb{R}^{N_f}$. Здесь $N_f = |\theta_m|$ – число признаков в полученном описании. Вектор параметров θ_i для каждого объекта находится решением оптимизационной задачи

$$\theta_m = \arg \min_{\theta} \|\hat{\mathbf{X}}_m - \mathbf{X}_m\|_2^2 \quad (1)$$

После построения признакового описания выборки $\mathbf{\Theta}_m$ строится модель регрессии $\hat{\mathbf{y}}_m = h(\mathbf{\Theta}_m, \mathbf{w})$, где \mathbf{w} – вектор параметров модели. Задается функция потерь на обучении $L(\mathbf{\Theta}, \mathbf{w}, \mathbf{y})$. Оптимальное значение вектора параметров \mathbf{w} модели h находится решением

57 ОПТИМИЗАЦИОННОЙ ЗАДАЧИ

$$\mathbf{w}^* = \arg \min_w L(\Theta, \mathbf{w}, \mathbf{y}) \quad (2)$$

58 **Описание алгоритма**

59 **Локальная аппроксимация сигнала нормальным распределени-**
 60 **ем**

61 Пусть заданы координаты каждого электрода на плоскости $Z = \{(\mathbf{z}_j \in \mathbb{R}^2, j \in$
 62 $\{1 \dots, N_{ch}\})\}$. Зафиксируем произвольный момент времени m , частоту f и задержку t .
 63 Обозначим $s_j = \underline{\mathbf{X}}_m^{(j,f,t)}$. Физический смысл s_j – амплитуда сигнала на электроде j . Будем
 64 строить аппроксимирующую модель как функцию плотности двумерного нормального
 65 распределения. Локальная модель сигнала определяться выборочным средним и выбо-
 66 рочной ковариацией координат электродов с весами, равными амплитуде.

$$g(\mathbf{x}, Z, \mathbf{s}) = \frac{1}{2\pi \det \Sigma^{-1}} \exp \left(\frac{1}{2} (\mathbf{x} - \mathbf{m})^T \Sigma (\mathbf{x} - \mathbf{m}) \right) \quad (3)$$

$$\mathbf{m}^{(f,t)} = \frac{\sum_{j=1}^{N_{ch}} s_j \mathbf{z}_j}{\sum_{j=1}^{N_{ch}} s_j} \quad (4)$$

$$\Sigma^{(f,t)} = \frac{1}{N_{ch}} Z^T \text{diag}(s) Z \quad (5)$$

В качестве новых признаков для описания сигнала используются параметры нормального распределения m , Σ , а так же их производные по времени

$$\mathbf{m}'^{(f,t)} = \frac{m^{(f,t+1)} - m^{(f,t-1)}}{2\Delta t}$$

$$\Sigma'^{(f,t)} = \frac{\Sigma^{(f,t+1)} - \Sigma^{(f,t-1)}}{2\Delta t}$$

Так как матрица ковариации симметрична, то новое признаковое описание имеет вид

$$\underline{\Theta}_m^{(f,t)} = [\mathbf{m}^{(f,t)}, \text{vec}(\Sigma^{(f,t)}), \mathbf{m}'^{(f,t)}, \text{vec}(\Sigma'^{(f,t)})]$$

PLS

Алгоритм частичных наименьших квадратов проецирует матрицу плана \mathbf{X} и целевую матрицу \mathbf{Y} в скрытое пространство малой размерностью l ($l < M$). Алгоритм PLS находит в скрытом пространстве матрицы $\mathbf{T}, \mathbf{U} \in \mathbb{R}^{m \times l}$, которые лучше всего описывают оригинальные матрицы \mathbf{X} и \mathbf{Y} . При этом PLS максимизирует взаимосвязь между \mathbf{T} и \mathbf{U} .

Матрица плана \mathbf{X} и целевая матрица \mathbf{Y} проецируются в скрытое пространство следующим образом:

$$\mathbf{X}_{m \times n} = \mathbf{T}_{m \times l} \cdot \mathbf{P}_{l \times n}^T + \mathbf{F}_{m \times n} = \sum_{k=1}^l \mathbf{t}_k_{m \times 1} \cdot \mathbf{p}_k^T_{1 \times n} + \mathbf{F}_{m \times n}, \quad (6)$$

$$\mathbf{Y}_{m \times r} = \mathbf{U}_{m \times l} \cdot \mathbf{Q}_{l \times r}^T + \mathbf{E}_{m \times r} = \sum_{k=1}^l \mathbf{u}_k_{m \times 1} \cdot \mathbf{q}_k^T_{1 \times r} + \mathbf{E}_{m \times r}. \quad (7)$$

Здесь \mathbf{T} и \mathbf{U} – образы исходных матриц в скрытом пространстве, причём столбцы матрицы \mathbf{T} ортогональны; \mathbf{P} и \mathbf{Q} – матрицы перехода; \mathbf{E} и \mathbf{F} – матрицы остатков. Алгоритм PLS максимизирует линейную зависимость между столбцами матриц \mathbf{T} и \mathbf{U}

$$\mathbf{U} \approx \mathbf{T}\mathbf{B}, \quad \mathbf{B} = \text{diag}(\beta_k), \quad \beta_k = \mathbf{u}_k^T \mathbf{t}_k / (\mathbf{t}_k^T \mathbf{t}_k).$$

Эксперимент

Предобработка данных

Обработка исходных данных в данной работе производится в несколько этапов и подробно описано в статье [8]. Исходный сигнал записан на частоте 1 kHz , данные о движении — на частоте 120 Hz . Сигнал фильтруется полосным фильтром с диапазоном от 0.3 Hz до 600 Hz . Затем для каждого момента времени t строится частотно-временная характеристика. Над сигналом в окне $[t - 1.1s, t]$ с шагом в $\Delta = 100$ миллисекунд осуществляется вейвлет-преобразование на 10 различных частотах ω_j в диапазоне от 10 до 150 Hz . Затем строится матрица 10×10 , элементами которой s_{ij} является квадрат амплитуды на частоте ω_j в момент времени $t - (1 + i)\Delta$. Таким образом, размер описания одного объекта (момента времени) составляет $N_{ch} \times 10 \times 10$.

Модель локальной аппроксимации строится на основе пердобработанных данных на каждой из 10 имеющихся частот и для каждого из моментов времени $t - (1 + i)\Delta$. Полученное новое признаковое описание имеет размер $10 \times 10 \times 10$

Ход эксперимента

В работе проеведены 3 эксперимента: PLS на пердобработанных данных, PLS на признаках локальной модели и PLS на объединении двух видов признаков. Результаты приведены в таблице:

	$n_c = 20$	$n_c = 40$	$n_c = 60$	$n_c = 80$
S	0.38	0.39	0.36	0.3
N	0.39	0.42	0.43	0.41

Литература

- [1] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiko Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ECoGs during periodic movements. *Frontiers in Neuroscience*, 8, dec 2014.
- [2] David M. Alexander, Peter Jurica, Chris Trengove, Andrey R. Nikolaev, Sergei Gepshtein, Mikhail Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, and Cees van Leeuwen. Traveling waves and trial averaging: The nature of single-trial and averaged brain responses in large-scale cortical signals. *NeuroImage*, 73:95–112, jun 2013.
- [3] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral components and kinematic recordings. *Journal of Neural Engineering*, 4(2):146–158, apr 2007.
- [4] Andrey Elishev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of Neural Engineering*, 11, oct 2014.
- [5] Carlos A. Loza and Jose C. Principe. Unsupervised robust detection of behavioral correlates in ECoG. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE, may 2017.

-
- [6] Roman Rosipal and Nicole Krämer. Overview and recent advances in partial least squares. In *Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer Berlin Heidelberg, 2006.
- [7] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ECoG) recording. *PLOS ONE*, 11(5):e0154878, may 2016.
- [8] Hai bin Zhao, Chun yang Yu, Chong Liu, and Hong Wang. ECoG-based brain-computer interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International Conference on Biomedical Engineering and Informatics*. IEEE, oct 2010.
- [9] Yilin Song, Yao Wang, and Jonathan Viventi. Unsupervised learning of spike patterns for seizure detection and wavefront estimation of high resolution micro electrocorticographic (μ ECoG) data. *IEEE Transactions on NanoBioscience*, 16(6):418–427, sep 2017.
- [10] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*. IEEE, aug 2014.
- [11] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ecog-based brain-computer interface. *Expert Systems with Applications*, 114, 07 2018.
- [12] I Rodriguez-Lujan, R Huerta, C Elkan, and C Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 2010.
- [13] Ziqian Xie. Deep learning approach for brain machine interface. 2018.
- [14] Nicholas Szrama David T Bundy, Mrinal Pahwa and Eric C Leuthardt. Decoding three-dimensional reaching movements using electrocorticographic signals in humans. *Journal of Neural Engineering*, 13, feb 2016.